Instructions pour l'utilisation de Google Cloud Platform

TP2 INF8111

Automne 2026

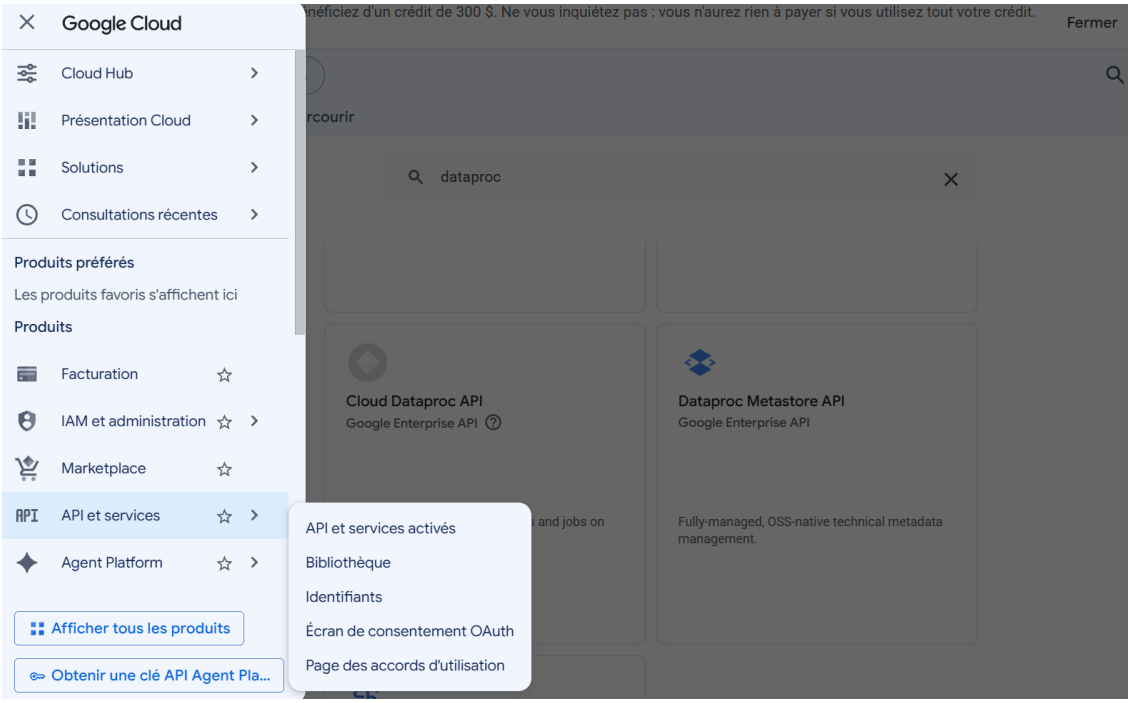
1 Obtention des crédits GCP

Avec l'URL fournie via Moodle, vous devez effectuer une demande pour obtenir des crédits GCP. Votre nom et votre adresse courriel (**@polymt.ca** ou **@etud.polymtl.ca**) vous seront demandés. Un courriel de confirmation vous sera ensuite envoyé, avec un lien vers le coupon.

Une fois cette étape validée, vous pourrez voir le détail de ces crédits via le lien suivant: https://console.cloud.google.com/billing (Crédits).

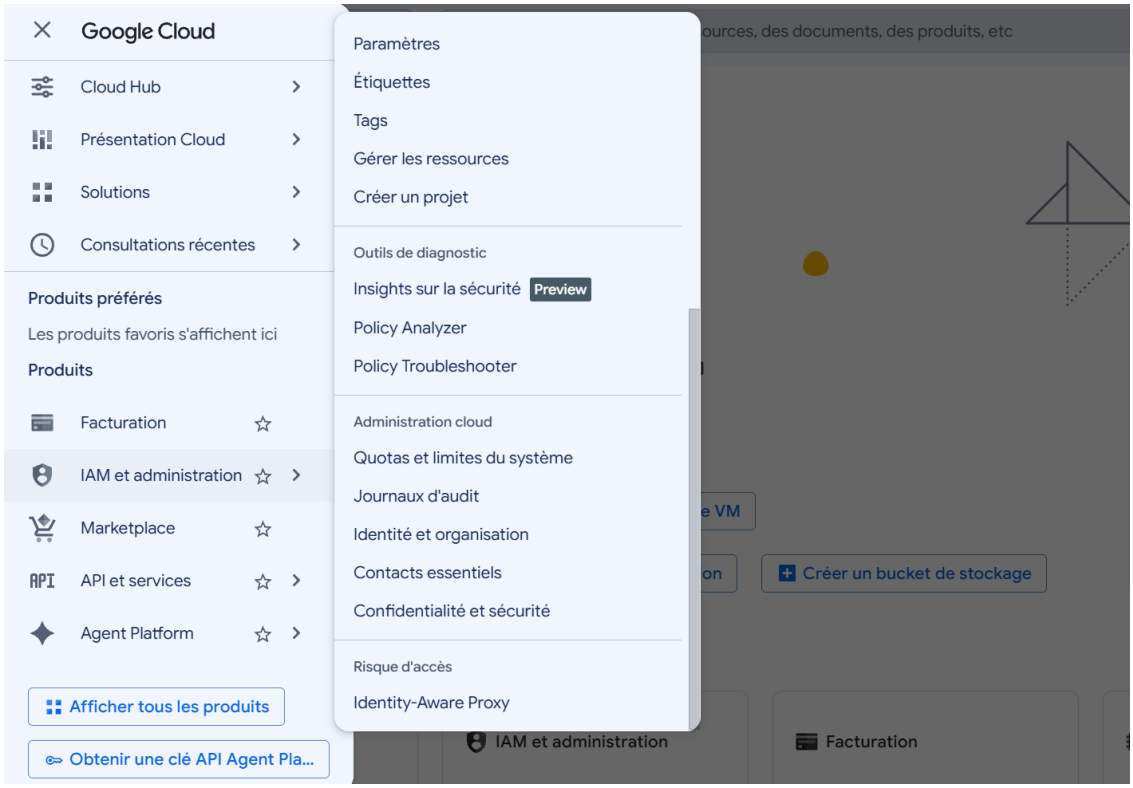
2 Activation des APIs requises

Pour exécuter l'algorithme, vous allez devoir préalablement avoir activé l'API. Pour cela, depuis votre compte, dans **API et services** → **Bibliothèque**, cherchez **Dataproc**. Ensuite, activer l'API **Cloud Dataproc API**.



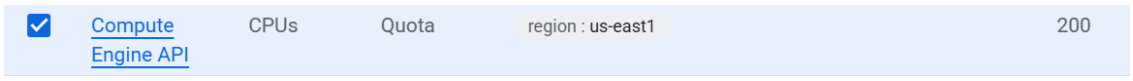
3 Augmentation du nombre de CPUs disponibles par clusters

Par défaut, il y a **12** CPUs alloués par GCP à chaque étudiant. Néanmoins, pour pouvoir exécuter notre algorithme, nous avons besoin de plus de ressources. Pour cela, cherchez **IAM et administration** → **Quotas et limites du système**. Une fois sur la page, recherchez **Compute Engine Api CPUs (all regions)** comme le montre les captures d'écran ci-dessous.





Cochez la ligne puis cliquez sur **Modifier le quota**. Entrez, par exemple, 128 comme nouvelle limite. Dans la description, écrivez quelque chose semblable à **I am working on an academic project that requires a large cluster to run the application**. Un courriel de confirmation vous sera alors envoyé. Cela peut prendre entre 30 minutes et 48 heures.
Vérifiez également que vous avez suffisamment de CPUs pour **Compute Engine Api CPUs (us-east1)**. Si ce n'est pas le cas, répétez la manœuvre précédente.



Notes:

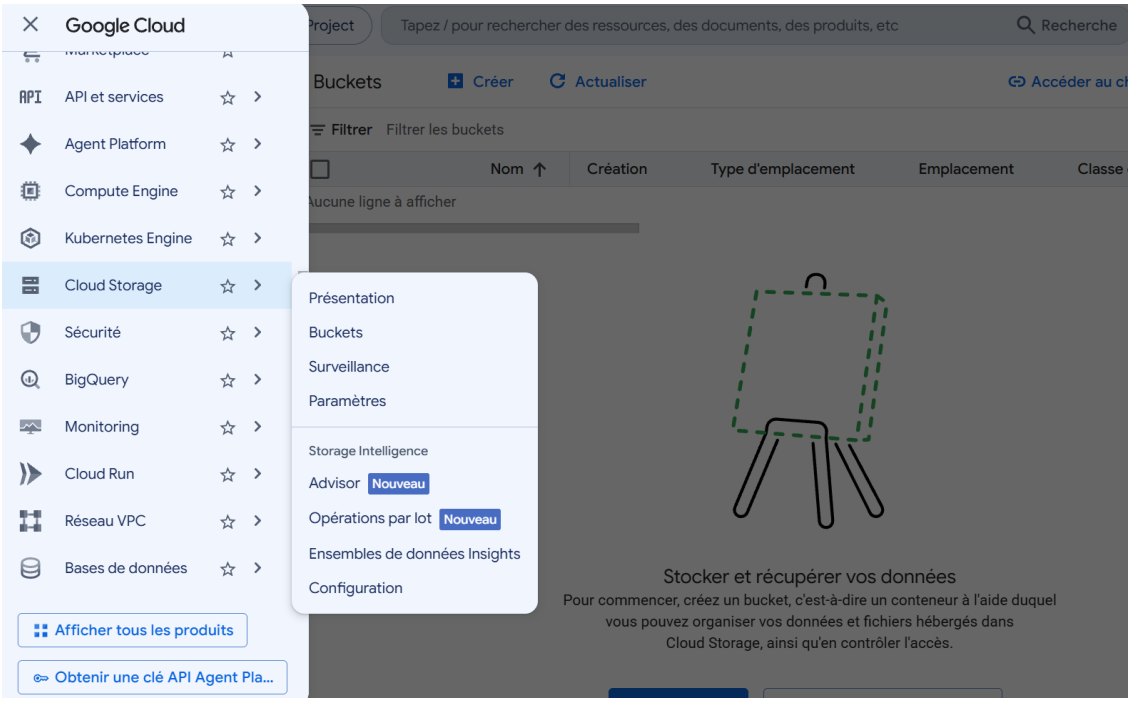
- Il est possible que votre demande soit refusée avec un message du type **Unfortunately, we are unable to grant you additional quota at this time. If this is a new project please wait 48h until you resubmit the request or until your Billing account has additional**

history. Dans ce cas, augmentez le nombre de CPUs progressivement : demandez 32 puis 64 et enfin 128.

- La configuration présente n'est que recommandée. Il est ainsi possible de demander plus de ressources.

4 Création d'un panier de stockage (storage bucket)

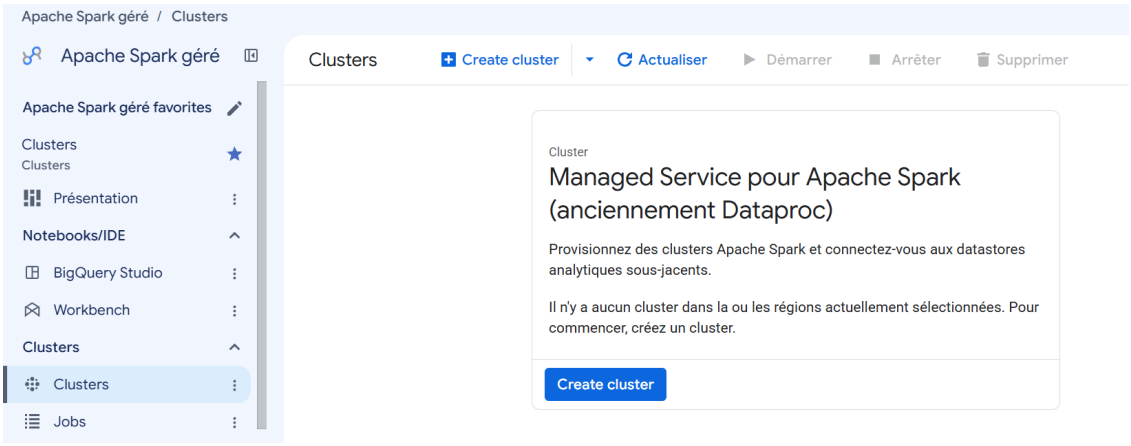
Il est nécessaire de charger les données que l'algorithme va utiliser. Vous devez ainsi créer un panier de stockage. Pour cela, rendez-vous dans la section **Cloud Storage** → **Buckets**. Créer ensuite un nouveau bucket.



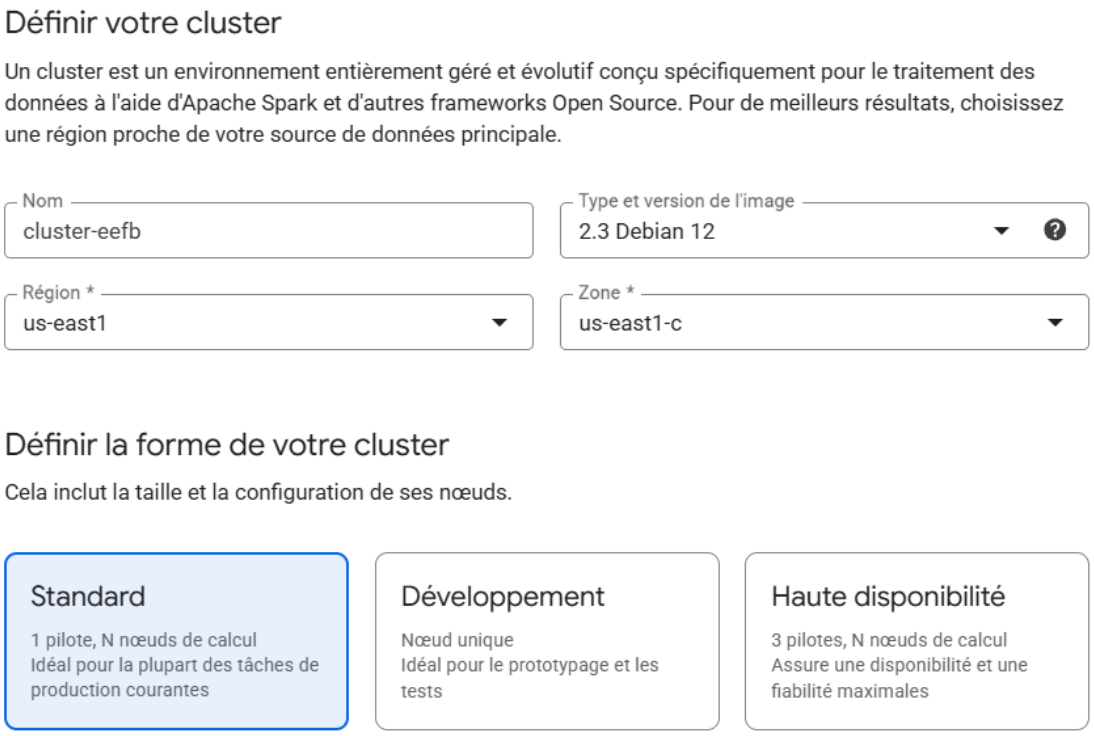
Puis, sélectionnez un nom. Dans la section **Choisissez où stocker vos données**, cochez **Region** avec **us-east1 (Caroline du Sud)** comme valeur. Une fois créé, vous serez redirigé vers une page d'où vous pouvez charger vos fichiers. L'URI Cloud Storage (sous Configuration) vous donnera la racine de ce dépôt. Il faudra en tenir compte lors de l'accès aux données depuis le notebook.

5 Création d'un cluster de calcul

Une fois le bucket créé, vous allez pouvoir créer le cluster. Rendez-vous dans la section **Apache Spark géré** → **Clusters**.



Une configuration possible est la suivante :



Configuration du nœud de calcul

✓ Usage général | Mémoire optimisée | Optimisé pour le stockage

Types de machines pour les charges de travail courantes permettant d'optimiser les coûts et la flexibilité

Série
N4

Basé sur une plate-forme de processeur Intel Emerald Rapids

Type de machine
n4-highmem-16 (16 vCPU, 8 cœur(s), 128 Go de mémoire)

vCPU	Memory
16	128 Go

Plate-forme du CPU et GPU

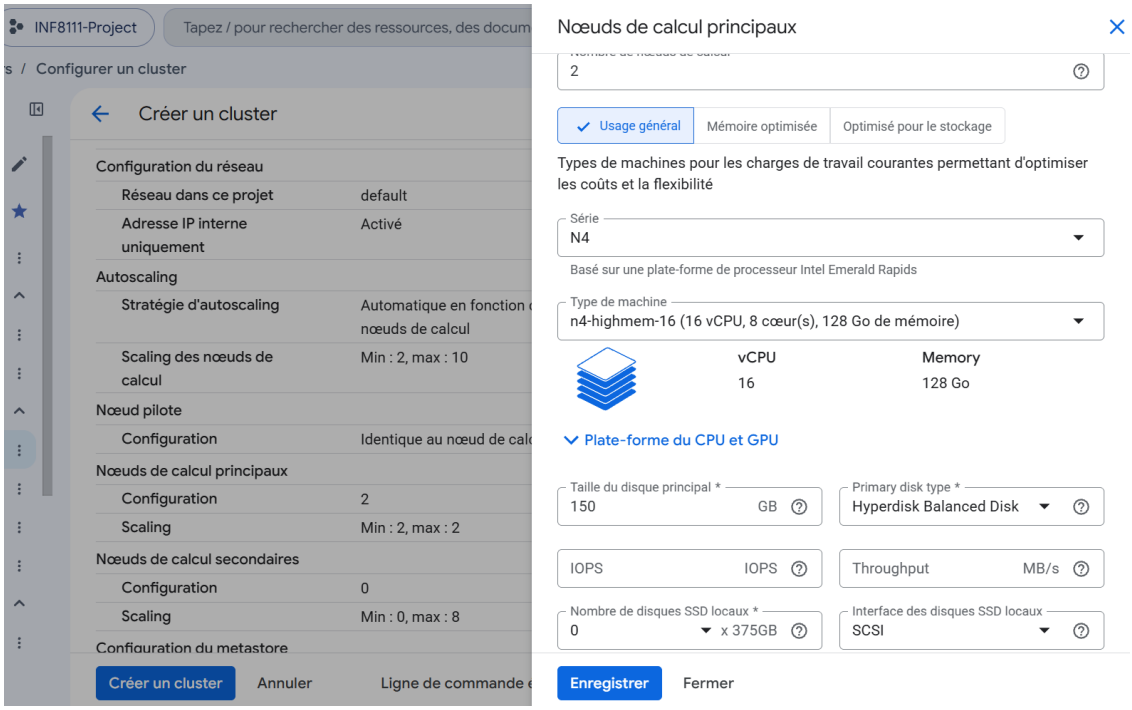
Choisir le mode de scaling des nœuds de calcul

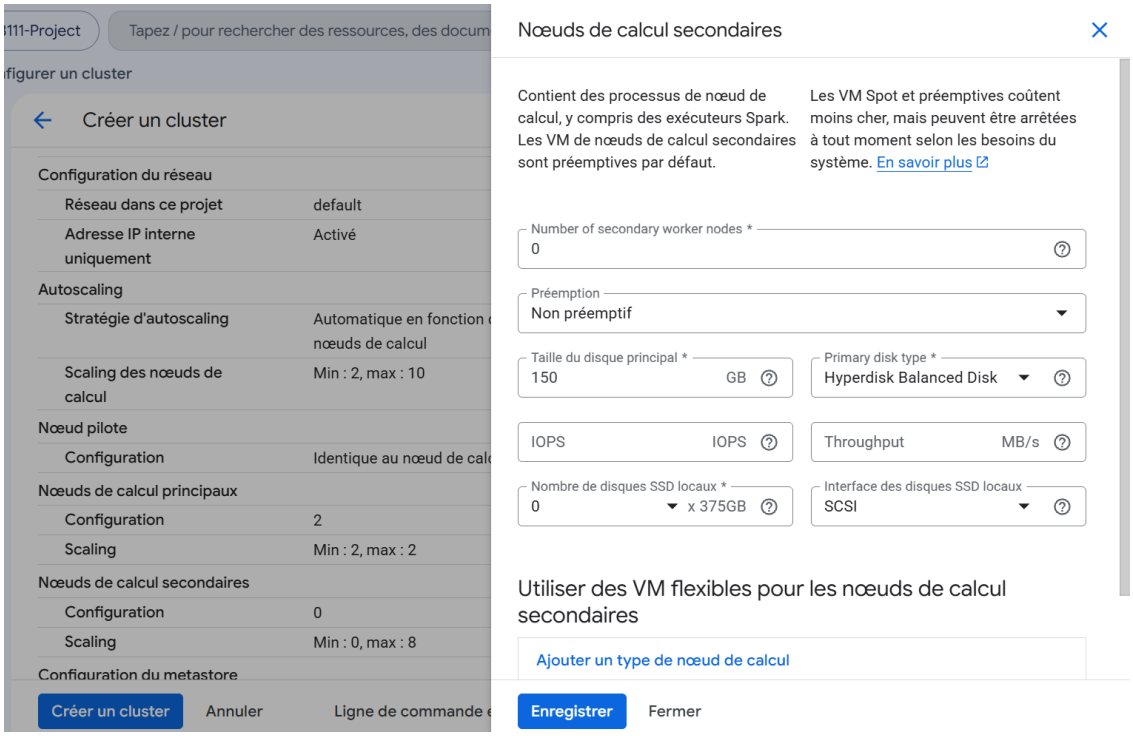
○ **Allocation fixe**
Définissez un nombre de nœuds de calcul pour bénéficier de coûts et de ressources de calcul fixes

◉ **Autoscaling**
Ajoute ou supprime automatiquement des nœuds de calcul pour s'adapter aux charges de travail exécutées sur le cluster

Nombre minimal de nœuds de calcul * : 2

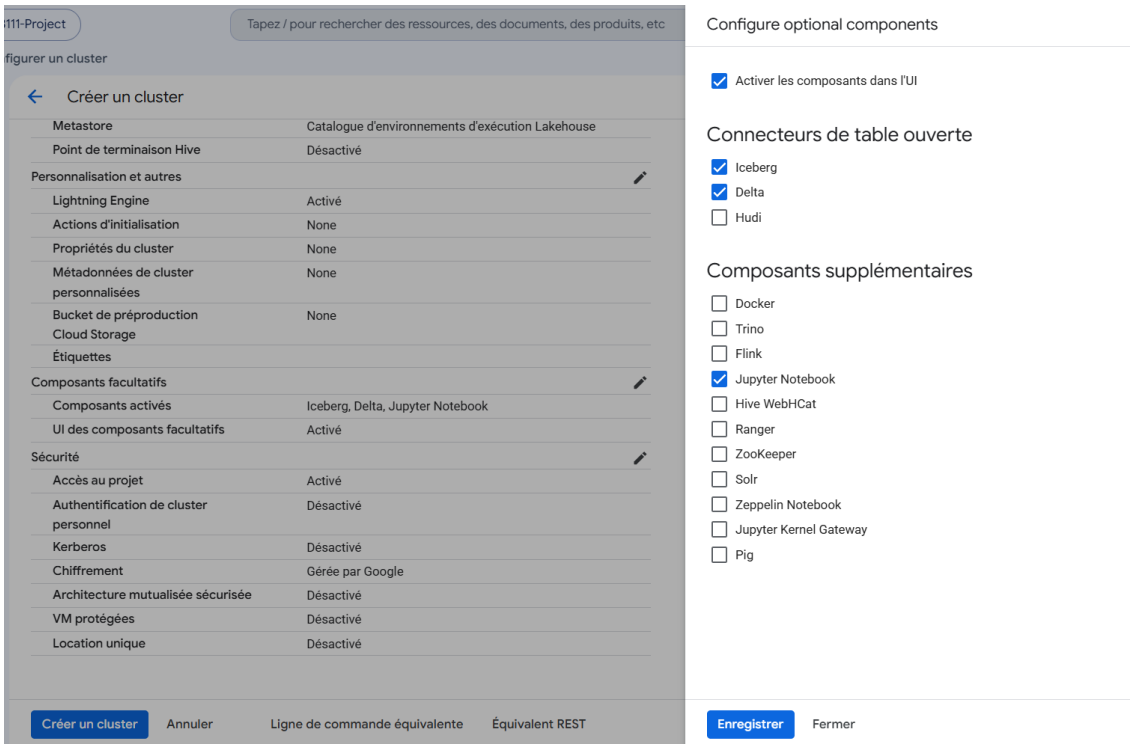
Nombre maximal de nœuds de calcul * : 10





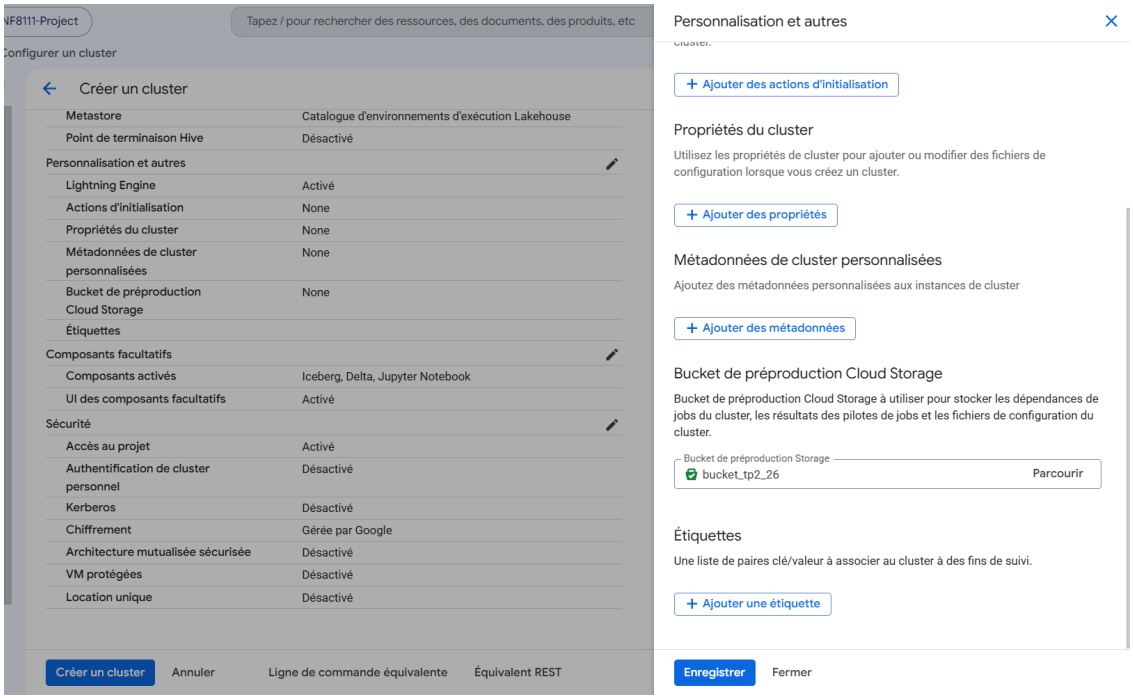
Notes:

- Il est important de sélectionner **Activer les composants dans l'UI** et **Jupyter Notebook**
- Le cluster créé possède 1 master pour 2 workers. Notre algorithme étant gourmand en mémoire, vous utiliserez des machines de type Highmen. Les captures d'écran présentent la configuration recommandée. Libre à vous d'en tester d'autres.



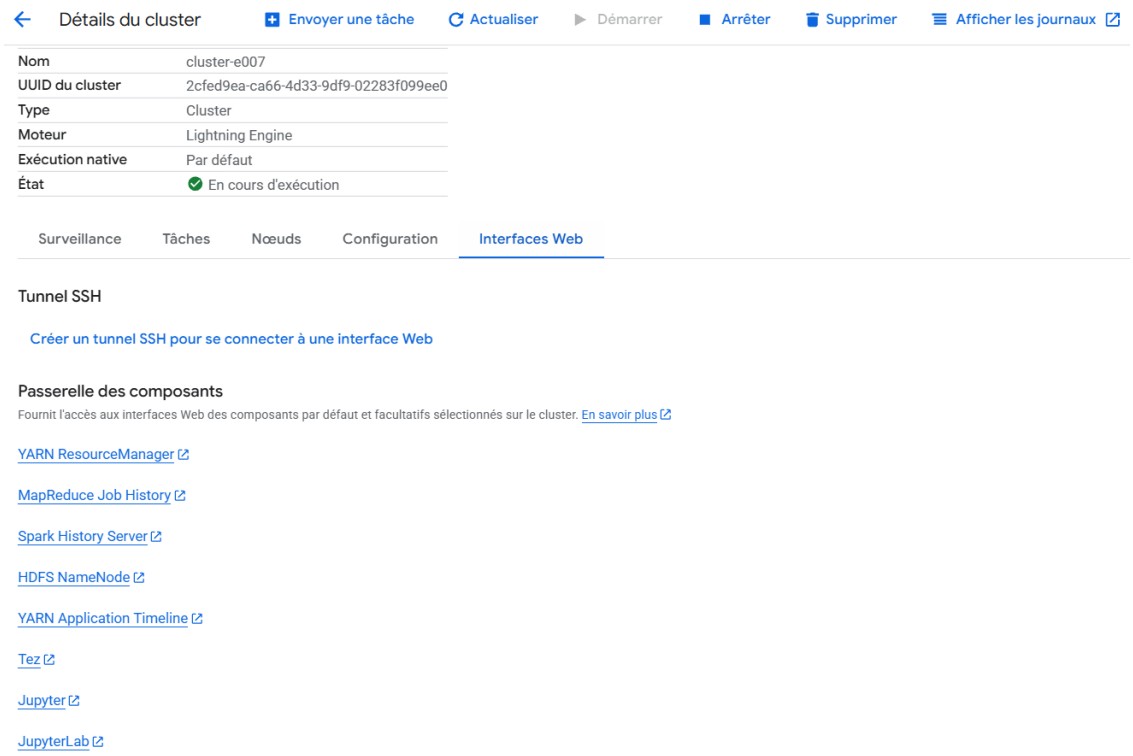
Enfin, vous devrez lier ce cluster au bucket créé précédemment. Cela s'effectue par le bucket de

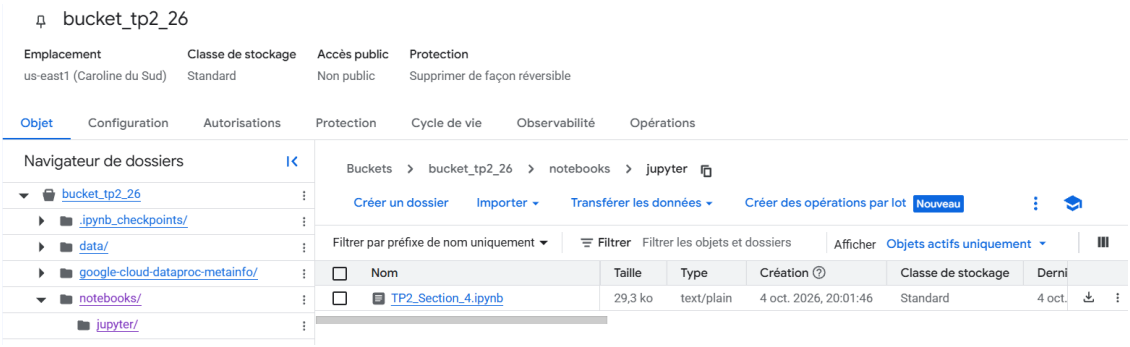
préproduction de Cloud Storage (sous Configuration suppémentaire).



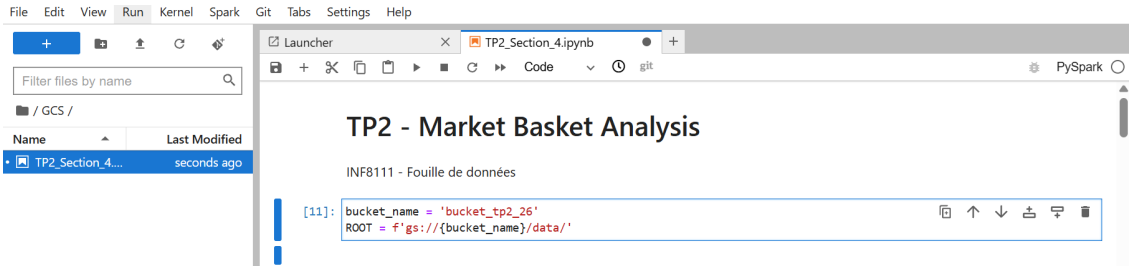
6 Utilisation du cluster

Une fois le cluster créé, cliquez dessus pour l'ouvrir. Rendez-vous dans la partie **Interfaces Web** puis cliquez sur le lien **JupyterLab**. Dans une nouvelle fenêtre, retournez dans le bucket précédemment créé, un dossier notebook/jupyter y a été ajouté. Importez votre notebook.





Vous devriez ainsi voir apparaître sur l'autre page ouverte (JupyterLab) votre notebook. Ouvrez-le puis sélectionnez, en haut à droite, le noyau PySpark (à la place de Python 3).



ATTENTION : Lorsque vous aurez fini la configuration du cluster et que vous cliquerez sur Créer, GCP commencera à prélever les 50$ de coupons. N'oubliez donc pas de supprimer ce cluster, ainsi que le panier de stockage, une fois que vous avez fini l'exécution.